

A4-Componentes Principales

Ricardo Salinas

2024-10-08

Análisis Descriptivo

#Primero se realiza un análisis descriptivo para conocer las variables. Incluye las medidas que vienen en el summary() y la desviación estándar. Describe las correlaciones que se establecen entre las variables.

```
print("Estos datos contienen informacion sobre dimensiones principales del cuerpo, los cuales se pueden utilizar para medir diferentes aspectos del cuerpo, contiene 6 columnas con diferentes medidas.")
```

```
## [1] "Estos datos contienen informacion sobre dimensiones principales del cuerpo, los cuales se pueden utilizar para medir diferentes aspectos del cuerpo, contiene 6 columnas con diferentes medidas."
```

```
corporal = read.csv("corporal.csv")
corporal1 = corporal[, -which(names(corporal) == "sexo")]
print(corporal)
```

```
##      edad peso altura  sexo muneca biceps
## 1     43  87.3  188.0 Hombre   12.2   35.8
## 2     65  80.0  174.0 Hombre   12.0   35.0
## 3     45  82.3  176.5 Hombre   11.2   38.5
## 4     37  73.6  180.3 Hombre   11.2   32.2
## 5     55  74.1  167.6 Hombre   11.8   32.9
## 6     33  85.9  188.0 Hombre   12.4   38.5
## 7     25  73.2  180.3 Hombre   10.6   38.3
## 8     35  76.3  167.6 Hombre   11.3   35.0
## 9     28  65.9  183.0 Hombre   10.2   32.1
## 10    26  90.9  183.0 Hombre   12.0   40.4
## 11    43  89.1  179.1 Hombre   11.3   36.5
## 12    30  62.3  170.2 Hombre   11.5   34.2
## 13    26  82.7  177.8 Hombre   11.5   35.2
## 14    51  79.1  179.1 Hombre   11.8   34.0
## 15    30  98.2  190.5 Hombre   10.7   34.8
## 16    24  84.1  177.8 Hombre   11.5   38.6
## 17    35  83.2  180.3 Hombre   11.1   36.4
## 18    37  83.2  180.3 Hombre   10.5   34.0
## 19    22  51.6  161.2  Mujer    9.2   24.3
## 20    20  59.0  167.5  Mujer    9.9   27.8
## 21    19  49.2  159.5  Mujer    8.9   24.0
## 22    25  63.0  157.0  Mujer    9.5   28.0
## 23    21  53.6  155.8  Mujer    9.1   26.9
```

```
## 24 23 59.0 170.0 Mujer 10.0 26.5
## 25 26 47.6 159.1 Mujer 9.4 24.1
## 26 22 69.8 166.0 Mujer 10.7 29.2
## 27 28 66.8 176.2 Mujer 9.8 29.0
## 28 40 75.2 160.2 Mujer 11.5 33.6
## 29 32 55.2 172.5 Mujer 8.6 24.8
## 30 25 54.2 170.9 Mujer 9.7 25.4
## 31 25 62.5 172.9 Mujer 9.2 25.9
## 32 29 42.0 153.4 Mujer 8.3 24.0
## 33 22 50.0 160.0 Mujer 8.6 25.6
## 34 25 49.8 147.2 Mujer 9.0 26.0
## 35 23 49.2 168.2 Mujer 9.6 23.5
## 36 37 73.2 175.0 Mujer 11.0 31.0

n = ncol(corporal1)
d = matrix(NA, ncol=7, nrow=n)
colnames(d) = c("Min", "Q1", "Median", "Mean", "Q3", "Max", "SD")

for (i in 1:n) {
  resumen = summary(corporal1[, i])
  desviacion = sd(corporal1[, i], na.rm = TRUE)
  d[i, ] = c(resumen[1], resumen[2], resumen[3], resumen[4], resumen[5],
resumen[6], desviacion)
}

print(d)

##      Min      Q1 Median      Mean      Q3      Max      SD
## [1,] 19.0 24.750 28.00 31.444444 37.00 65.0 10.554469
## [2,] 42.0 54.950 71.50 68.95278 82.40 98.2 14.868999
## [3,] 147.2 164.800 172.70 171.55556 179.40 190.5 10.520170
## [4,] 8.3 9.475 10.65 10.46667 11.50 12.4 1.175463
## [5,] 23.5 25.975 32.15 31.16667 35.05 40.4 5.234392
```

PARTE 1

#Realiza el análisis de los valores y vectores propios con la matriz de covarianzas y con la de correlación. Analiza la varianza explicada por cada componente en cada caso e interpreta dentro del contexto del problema.

#1. Calcule las matrices de varianza-covarianza S con cov(X) y la matriz de correlaciones R con cor(X) y realice los siguientes pasos con cada una:

```
s = cov(corporal1)
```

```
r = cor(corporal1)
```

#-Calcule los valores y vectores propios de cada matriz. La función en R es: eigen().

```
eigen_s = eigen(s)
print(eigen_s)

## eigen() decomposition
## $values
## [1] 359.3980243  80.3757858  27.6229011   4.3074318   0.2343571
##
## $vectors
##           [,1]      [,2]      [,3]      [,4]      [,5]
## [1,] -0.34871002  0.9075501 -0.23248825 -0.001589466  0.026473941
## [2,] -0.76617586 -0.1616581  0.52166894 -0.338508602  0.010707863
## [3,] -0.47632405 -0.3851755 -0.78905759  0.046160807  0.003543154
## [4,] -0.05386189  0.0155423  0.02785902  0.126103480 -0.990039959
## [5,] -0.24817367 -0.0402221  0.22455005  0.931330496  0.137814357
```

```
eigen_r = eigen(r)
print(eigen_r)

## eigen() decomposition
## $values
## [1] 3.75749733 0.72585665 0.32032981 0.12461873 0.07169749
##
## $vectors
##           [,1]      [,2]      [,3]      [,4]      [,5]
## [1,] -0.3359310  0.8575601 -0.34913780 -0.1360111  0.1065123
## [2,] -0.4927066 -0.1647821  0.06924561 -0.5249533 -0.6706087
## [3,] -0.4222426 -0.4542223 -0.73394453  0.2070673  0.1839617
## [4,] -0.4821923  0.1082775  0.36690716  0.7551547 -0.2255818
## [5,] -0.4833139 -0.1392684  0.44722747 -0.3046138  0.6739511
```

#2. Calcule la proporción de varianza explicada por cada componente en ambas matrices. Se sugiere dividir cada lambda entre la varianza total (Las lambdas están en `eigen(S)$values`). La varianza total es la suma de las varianzas de la diagonal de S . Una forma es `sum(diag(S))`. La varianza total de los componentes es la suma de los valores propios (es decir, la suma de la varianza de cada componente), sin embargo, si sumas la diagonal de S (es decir, la varianza de cada x), te da el mismo valor (¡compruébalo!). Recuerda que las combinaciones lineales buscan reproducir la varianza de X .

```
varianza_total_s <- sum(eigen_s$values)

proporcion_varianza_s <- eigen_s$values / varianza_total_s
print(proporcion_varianza_s)

## [1] 0.7615357176 0.1703098726 0.0585307219 0.0091271040 0.0004965839

varianza_total_r <- sum(eigen_r$values)

proporcion_varianza_r <- eigen_r$values / varianza_total_r
print(proporcion_varianza_r)
```

```
## [1] 0.75149947 0.14517133 0.06406596 0.02492375 0.01433950
```

#3. Acumule los resultados anteriores (cumsum() puede servirle) para obtener la varianza acumulada en cada componente.

```
varianza_acumulada_s <- cumsum(proporcion_varianza_s)
print("Varianza S")
```

```
## [1] "Varianza S"
```

```
print(varianza_acumulada_s)
```

```
## [1] 0.7615357 0.9318456 0.9903763 0.9995034 1.0000000
```

```
varianza_acumulada_r <- cumsum(proporcion_varianza_r)
print("Varianza R")
```

```
## [1] "Varianza R"
```

```
print(varianza_acumulada_r)
```

```
## [1] 0.7514995 0.8966708 0.9607368 0.9856605 1.0000000
```

#4. Según los resultados anteriores, ¿qué componentes son los más importantes?

```
print("Con los datos vistos, podemos definir que los primeros dos componentes son los mas utiles, ya que nos dan un valor de 0.9318456, lo cual es optimo para tratar de reducir los componentes y mantener un buen valor.")
```

```
## [1] "Con los datos vistos, podemos definir que los primeros dos componentes son los mas utiles, ya que nos dan un valor de 0.9318456, lo cual es optimo para tratar de reducir los componentes y mantener un buen valor."
```

#5. Escriba la ecuación de la combinación lineal de los Componentes principales CP1 y CP2 (e_1X , donde e_1 está en $eigen(S)$vectors[1]$, e_2X para obtener CP2, donde $X = c(X_1, X_2, \dots)$) ¿qué variables son las que más contribuyen a la primera y segunda componentes principales? (observe los coeficientes en valor absoluto de las combinaciones lineales). Justifique su respuesta.

```
etiquetas = colnames(corporal1)
```

```
CP1_coeficientes_S = eigen_s$vectors[,1]
CP1_combinacion_S = data.frame(Variable = etiquetas, Coeficiente_CP1_S =
CP1_coeficientes_S)
```

```
CP2_coeficientes_S = eigen_s$vectors[,2]
CP2_combinacion_S = data.frame(Variable = etiquetas, Coeficiente_CP2_S =
CP2_coeficientes_S)
```

```
print("Combinación lineal de CP1 para la matriz de covarianza (S):")
```

```

## [1] "Combinación lineal de CP1 para la matriz de covarianza (S):"

print(CP1_combinacion_S)

##   Variable Coeficiente_CP1_S
## 1   edad      -0.34871002
## 2   peso      -0.76617586
## 3   altura    -0.47632405
## 4   muneca    -0.05386189
## 5   biceps    -0.24817367

print("Combinación lineal de CP2 para la matriz de covarianza (S):")

## [1] "Combinación lineal de CP2 para la matriz de covarianza (S):"

print(CP2_combinacion_S)

##   Variable Coeficiente_CP2_S
## 1   edad      0.9075501
## 2   peso      -0.1616581
## 3   altura    -0.3851755
## 4   muneca     0.0155423
## 5   biceps    -0.0402221

CP1_coeficientes_R = eigen_r$vectors[,1]
CP1_combinacion_R = data.frame(Variable = etiquetas, Coeficiente_CP1_R =
CP1_coeficientes_R)

CP2_coeficientes_R = eigen_r$vectors[,2]
CP2_combinacion_R = data.frame(Variable = etiquetas, Coeficiente_CP2_R =
CP2_coeficientes_R)

print("Combinación lineal de CP1 para la matriz de correlación (R):")

## [1] "Combinación lineal de CP1 para la matriz de correlación (R):"

print(CP1_combinacion_R)

##   Variable Coeficiente_CP1_R
## 1   edad      -0.3359310
## 2   peso      -0.4927066
## 3   altura    -0.4222426
## 4   muneca    -0.4821923
## 5   biceps    -0.4833139

print("Combinación lineal de CP2 para la matriz de correlación (R):")

## [1] "Combinación lineal de CP2 para la matriz de correlación (R):"

print(CP2_combinacion_R)

##   Variable Coeficiente_CP2_R
## 1   edad      0.8575601

```

```
## 2    peso      -0.1647821
## 3    altura    -0.4542223
## 4    muneca     0.1082775
## 5    biceps    -0.1392684
```

#¡No te olvides de seguir los mismos pasos con la matriz de correlaciones (se obtiene con cor(x) si x está compuesto por variables numéricas)

Parte 2

#Obtenga las gráficas respectivas con S (matriz de varianzas-covarianzas) y con R (matriz de correlaciones) de las dos primeras componentes.


```
cpS = princomp(corporal1, cor=FALSE)
summary(cpS)
```

```
## Importance of components:
```

```
##              Comp.1    Comp.2    Comp.3    Comp.4
Comp.5
## Standard deviation    18.6926388  8.8398600  5.18223874  2.046406827
0.4773333561
## Proportion of Variance  0.7615357  0.1703099  0.05853072  0.009127104
0.0004965839
## Cumulative Proportion  0.7615357  0.9318456  0.99037631  0.999503416
1.0000000000
```


```
plot(cpS$scores[, 1:2], type="p", main="Componentes principales con matriz de
covarianza (S)")
text(cpS$scores[, 1], cpS$scores[, 2], labels=1:nrow(cpS$scores), pos=3)
```

Componentes principales con matriz de covarianza



```
biplot(cpS, main="Biplot con matriz de covarianza (S)")
```

Biplot con matriz de covarianza (S)



```
cpR = princomp(corporal1, cor=TRUE)
summary(cpR)
```


```
## Importance of components:
```

```
##              Comp.1    Comp.2    Comp.3    Comp.4    Comp.5
## Standard deviation  1.9384265 0.8519722 0.56597686 0.35301378 0.2677639
## Proportion of Variance 0.7514995 0.1451713 0.06406596 0.02492375 0.0143395
## Cumulative Proportion 0.7514995 0.8966708 0.96073676 0.98566050 1.0000000
```

```
plot(cpR$scores[, 1:2], type="p", main="Componentes principales con matriz de correlación (R)")
```


```
text(cpR$scores[, 1], cpR$scores[, 2], labels=1:nrow(cpR$scores), pos=3)
```


Componentes principales con matriz de correlación



```
biplot(cpR, main="Biplot con matriz de correlación (R)")
```

Biplot con matriz de correlación (R)




#Calcule las puntuaciones (scores) de las observaciones para los componentes obtenidos con la matriz de varianzas-covarianzas


```
cpS = princomp(corporal1, cor = FALSE)
cpaS = as.matrix(corporal1) %*% cpS$loadings
```

```
plot(cpaS[,1:2], type = "p", main = "PCA con matriz de covarianza (S)")
text(cpaS[,1], cpaS[,2], labels = 1:nrow(cpaS))
```

PCA con matriz de covarianza (S)



`biplot(cpS)`




#Calcule las puntuaciones (scores) de las observaciones para los componentes obtenidos con la matriz de correlaciones. Recuerde que en la matriz de correlaciones las variables tienen que estar estandarizadas.


```
cpR <- princomp(corporal1, cor = TRUE)
cpaR <- as.matrix(scale(corporal1)) %*% cpR$loadings

plot(cpaR[,1:2], type = "p", main = "PCA con matriz de correlación (R)")
text(cpaR[,1], cpaR[,2], labels = 1:nrow(cpaR))
```

PCA con matriz de correlación (R)



`biplot(cpR)`



#Explora el: `princomp()` en `library(stats)`. Puedes poner `help(princomp)` en la consola o buscarlo en la ventana de ayuda. Indaga: ¿qué otras opciones tiene para facilitarte el análisis? En particular, explora los comandos y subcomandos: `summary(cpS)`, `cpa$loading`, `cpa$scores`. ¿Cómo se interpreta el resultado?

`summary(cpS)`

Importance of components:

	Comp.1	Comp.2	Comp.3	Comp.4	Comp.5
## Standard deviation	18.6926388	8.8398600	5.18223874	2.046406827	0.4773333561
## Proportion of Variance	0.7615357	0.1703099	0.05853072	0.009127104	0.0004965839
## Cumulative Proportion	0.7615357	0.9318456	0.99037631	0.999503416	1.0000000000

`cpS$loadings`

##

Loadings:

	Comp.1	Comp.2	Comp.3	Comp.4	Comp.5
## edad	0.349	0.908	0.232		

```
## peso      0.766 -0.162 -0.522  0.339
## altura    0.476 -0.385  0.789
## muneca                    -0.126 -0.990
## biceps    0.248          -0.225 -0.931  0.138
##
##              Comp.1 Comp.2 Comp.3 Comp.4 Comp.5
## SS loadings      1.0   1.0   1.0   1.0   1.0
## Proportion Var    0.2   0.2   0.2   0.2   0.2
## Cumulative Var    0.2   0.4   0.6   0.8   1.0
```


```
head(cpS$scores)
```


```
##              Comp.1      Comp.2      Comp.3      Comp.4      Comp.5
## [1,] 27.162853  1.0278492  5.0022646  0.93622690 -0.51688356
## [2,] 22.363542 27.5955807  3.0635949 -0.08338126  0.02552809
## [3,] 19.167874  7.9566157 -1.5770026 -2.61077676  0.80391745
## [4,]  9.959001  0.8923731  5.5146952  0.12345373 -0.35579895
## [5,] 10.775593 22.0203437 -0.7562826  0.17996723 -0.41646606
## [6,] 23.283948 -7.9268214  2.7958617 -2.09339284 -0.62252321
```

Parte 3


#Explore los siguientes gráficos relativos a Componentes Principales.

```
library(FactoMineR)
library(ggplot2)
datos=corporal1
cpS = PCA(datos,scale.unit=FALSE)
```





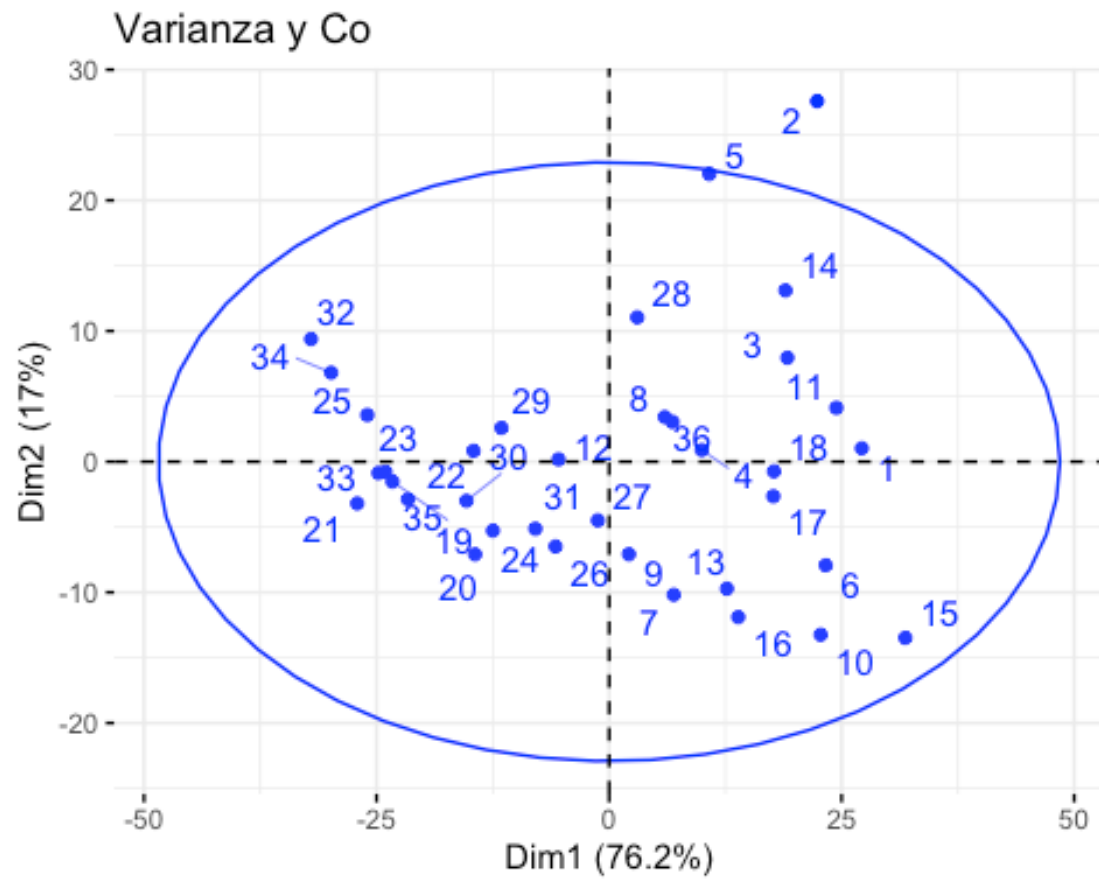
```
cpR = PCA(datos, scale.unit=TRUE)
```




```
library(factoextra)
```

```
## Welcome! Want to learn more? See two factoextra-related books at  
https://goo.gl/ve3WBa
```

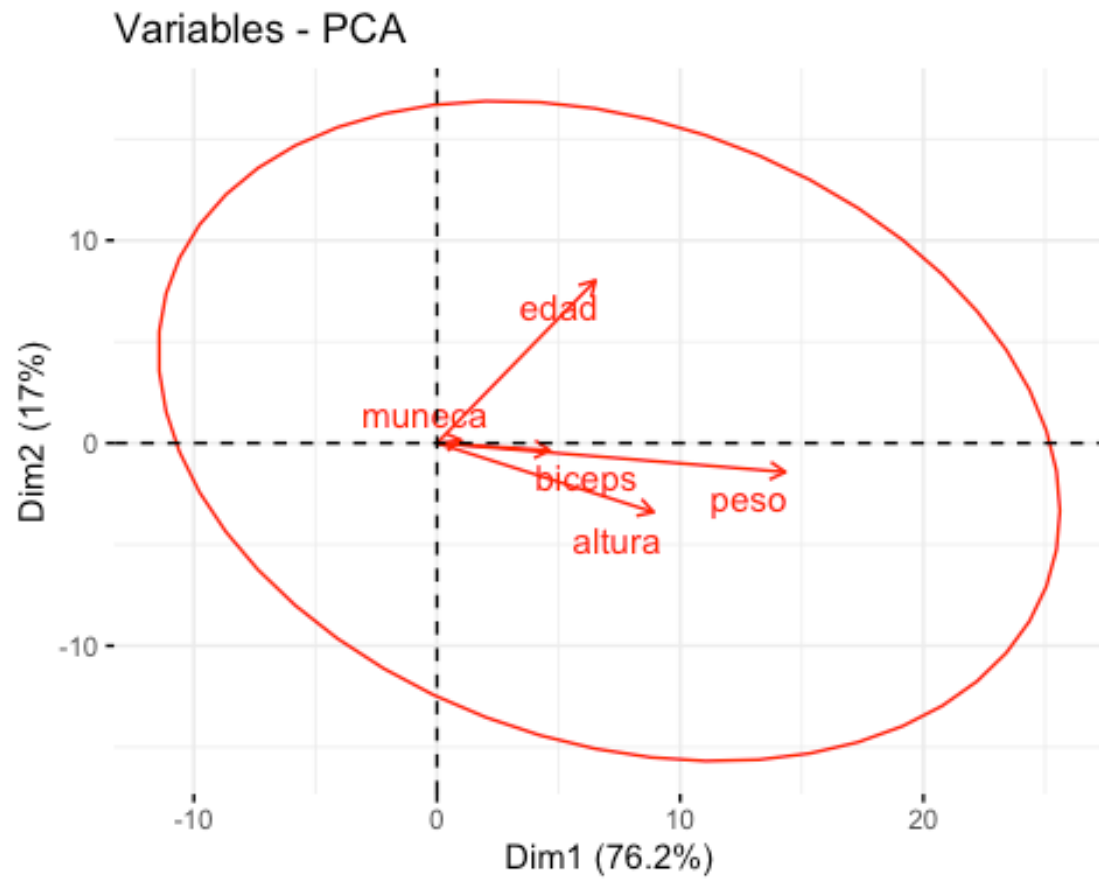
```
fviz_pca_ind(cpS, col.ind = "blue", addEllipses = TRUE, repel = TRUE,  
title="Varianza y Co")
```



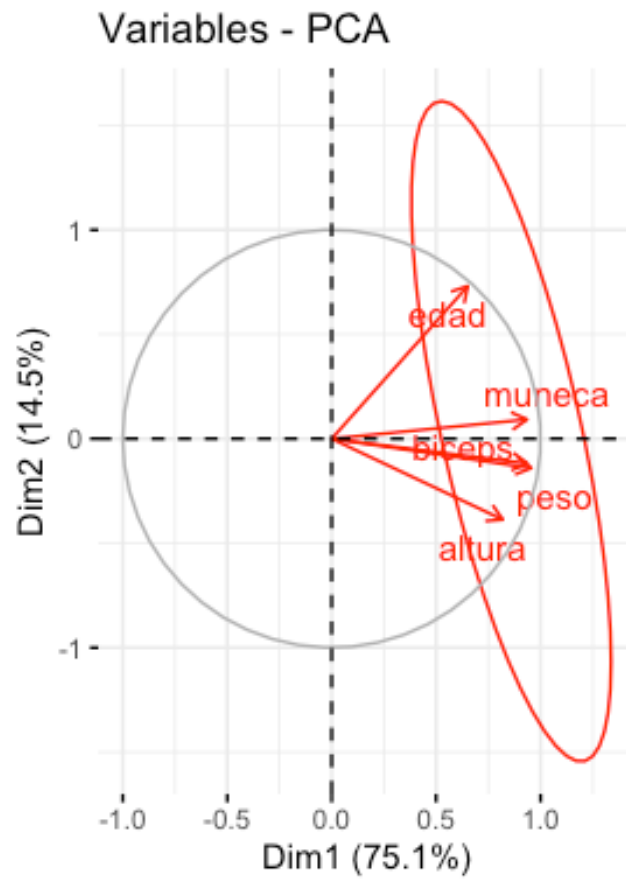
```
fviz_pca_ind(cpR, col.ind = "blue", addEllipses = TRUE, repel = TRUE,
title="Correlación")
```




```
fviz_pca_var(cpS, col.var = "red", addEllipses = TRUE, repel = TRUE)
```




```
fviz_pca_var(cpR, col.var = "red", addEllipses = TRUE, repel = TRUE)
```




```
fviz_screplot(cpS)
```



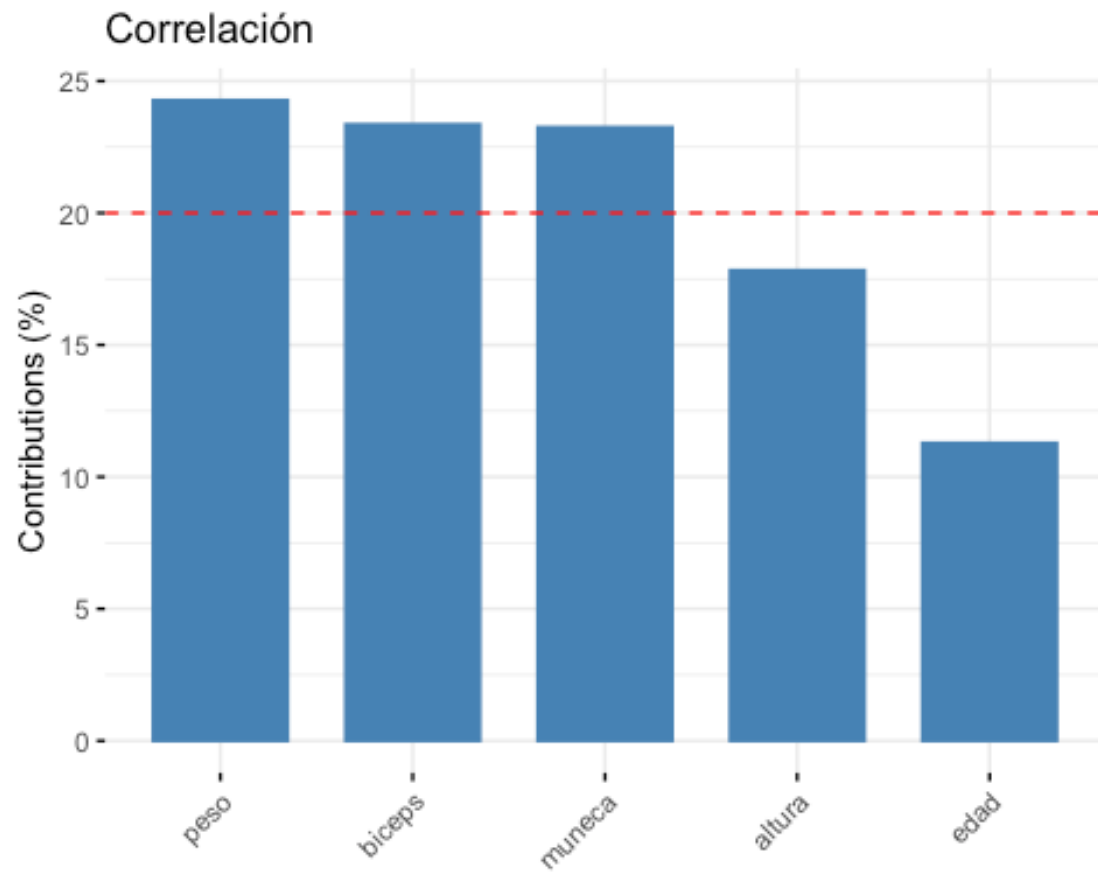
```
fviz_screplot(cpR)
```




```
fviz_contrib(cpS, choice = c("var"), title="Varianza y Co")
```

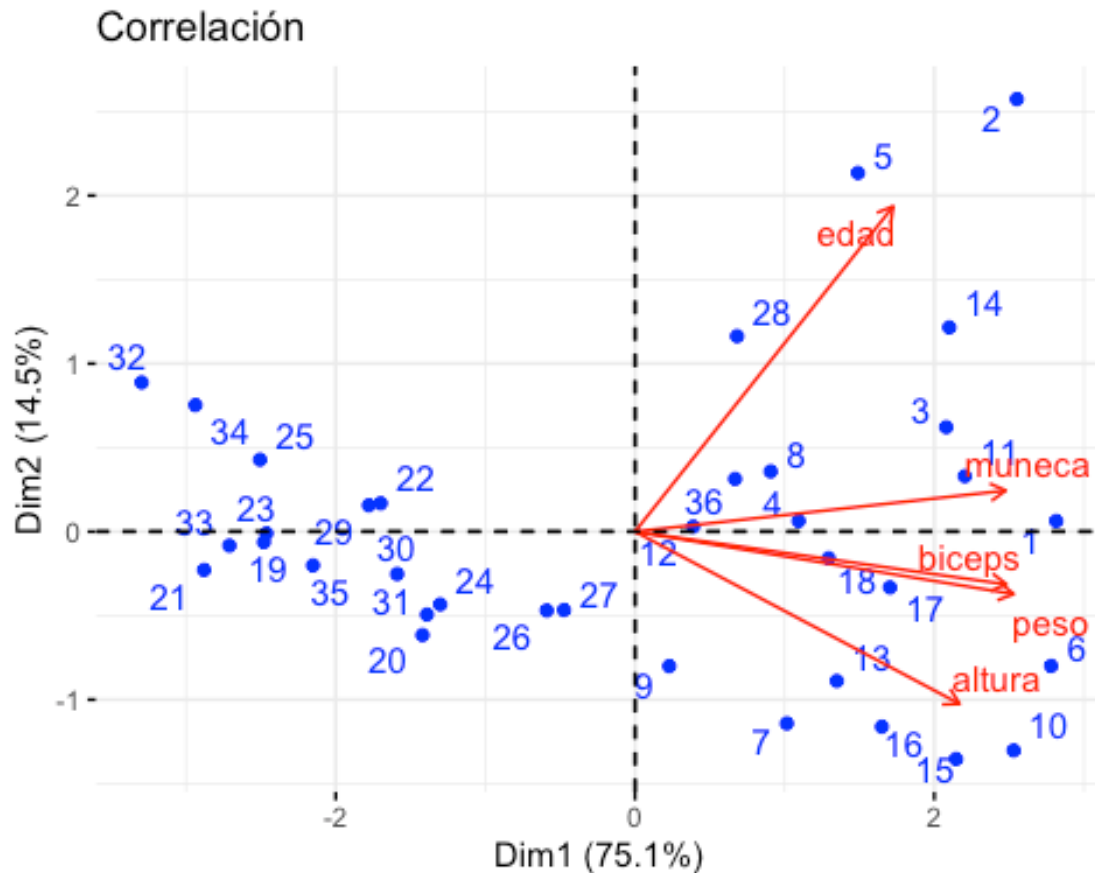
```
fviz_contrib(cpR, choice = c("var"), title="Correlación")
```



```
fviz_pca_biplot(cpS, repel=TRUE, col.var="red", col.ind="blue",  
title="Varianza y Co")
```



```
fviz_pca_biplot(cpR, repel=TRUE, col.var="red", col.ind="blue",
title="Correlación")
```



#Interprete cada gráfico e identifica qué es lo que se está graficando en cada uno. Realiza el análisis con la matriz de varianzas y covarianzas y correlación.

```
print("Observaciones:")
```

```
## [1] "Observaciones:"
```

```
print("La primera grafica nos define cuales variables llegan a ser similares, casi todos los datos tienen características similares, pero en cuanto a datos atipicos tenemos el numero 2")
```

```
## [1] "La primera grafica nos define cuales variables llegan a ser similares, casi todos los datos tienen características similares, pero en cuanto a datos atipicos tenemos el numero 2"
```

```
print("La segunda grafica muestra la cantidad de correlacion que tienen las variables dependiendo de su cercania.")
```

```
## [1] "La segunda grafica muestra la cantidad de correlacion que tienen las variables dependiendo de su cercania."
```

```
print("El tercer grafico contiene tanto la varianza como la correlacion explicadas para cada componente.")
```

```
## [1] "El tercer grafico contiene tanto la varianza como la correlacion
explicadas para cada componente."

print("El cuarto grafico nos muestra como el peso y la altura tienen un gran
peso en la varianza.")

## [1] "El cuarto grafico nos muestra como el peso y la altura tienen un gran
peso en la varianza."

print("El quinto grafico nos muestra la relacion entre los datos y las
variables, esto definido por las lineas azules, las lineas rojas muestran el
peso que tienen estas variables en los componentes principales.")

## [1] "El quinto grafico nos muestra la relacion entre los datos y las
variables, esto definido por las lineas azules, las lineas rojas muestran el
peso que tienen estas variables en los componentes principales."

print("Conclusion:")

## [1] "Conclusion:"

print("Como todas las variables hablan de una diferente medida del cuerpo muy
diferente, el metodo de correlacion permite que cada una tenga su respectivo
peso en el analisis, asi teniendo un mejor analisis en general.")

## [1] "Como todas las variables hablan de una diferente medida del cuerpo
muy diferente, el metodo de correlacion permite que cada una tenga su
respectivo peso en el analisis, asi teniendo un mejor analisis en general."
```